

INFORME TÉCNICO

BI para Análisis Integral de Ventas, Inventario y Rentabilidad

Materia	Bases de Datos Avanzadas — SI3009 (2026-1)
Universidad	EAFIT — Ingeniería de Sistemas
Proyecto	Proyecto 3
Fecha	Mayo 2026

Integrantes del Equipo

#	Nombre	Responsabilidad Principal
1	Alejandro Sepúlveda	Infraestructura Azure/AWS + Base OLTP
2	Sebastián Durán	Staging + ETL Dimensiones + Calidad de Datos
3	Juan Simón Ospina	Data Warehouse + ETL Hechos + Validaciones
4	Daniel Arcial	Power BI + Modelo Semántico + Informe Técnico

El proyecto implementa un pipeline de Business Intelligence end-to-end sobre SQL Server en AWS RDS. Los datos fluyen desde la base transaccional RetailOLTP (13 tablas, 50.000 ventas, 150.000 líneas), pasan por la zona de integración BI_Staging donde se aplican transformaciones y validaciones de calidad, y llegan al Data Warehouse RetailDW (modelo estrella: 9 dimensiones + 4 hechos) que alimenta 6 páginas de dashboard en Power BI Service.

Tabla de Contenido

1.	Descripción del Caso de Negocio	...
2.	Arquitectura General de la Solución	...
3.	Base de Datos OLTP — RetailOLTP	...
4.	Zona de Staging — BI_Staging	...
5.	Data Warehouse — RetailDW	...
6.	Justificación del Modelo Dimensional	...
7.	Procesos ETL en T-SQL	...
8.	Validaciones y Calidad de Datos	...
9.	Visualización en Power BI	...
10.	Medidas DAX	...
11.	Fuentes de Datos Externas	...
12.	Ética y Uso de IA en el Proyecto	...
13.	Conclusiones	...
14.	Referencias	...

1. Descripción del Caso de Negocio

Una empresa minorista con 10 sedes en Colombia requirió una solución completa de Business Intelligence para consolidar su operación comercial y habilitar la toma de decisiones gerenciales basadas en datos. La organización contaba con datos transaccionales dispersos en una base relacional OLTP, archivos planos históricos y hojas de cálculo utilizadas por cada sede para registrar metas e inventarios físicos.

Necesidades de la gerencia

- Ventas y rentabilidad por producto, tienda, vendedor y canal.
- Comportamiento de clientes por segmento (VIP, Premium, Regular, General).
- Control de inventario: rotación, quiebres de stock y días de cobertura.
- Cumplimiento de metas comerciales mensuales por tienda y categoría.
- Variación interanual y desempeño regional.

Alcance técnico de la solución

- Base de datos OLTP normalizada en SQL Server con 13+ tablas y 50.000+ ventas.
- Zona de staging (BI_Staging) con validaciones y transformaciones de calidad.
- Data Warehouse dimensional en estrella (RetailDW): 9 dimensiones + 4 tablas de hechos.
- ETL completo en T-SQL (procedimientos almacenados + orquestador maestro).
- Modelo semántico y 6 páginas de dashboard en Power BI Service (nube pública).
- Infraestructura desplegada en AWS RDS + publicación en app.powerbi.com.

2. Arquitectura General de la Solución

La arquitectura sigue el patrón clásico de tres capas para soluciones BI: capa operacional (OLTP), capa de integración (Staging) y capa analítica (DW + Power BI).

Capa	Base de Datos / Herramienta	Descripción
Operacional	RetailOLTP (SQL Server)	13 tablas relacionales normalizadas en 3FN. 50K ventas, 175K líneas, 1K clientes, 200 productos.
Integración	BI_Staging (SQL Server)	Tablas intermedias con limpieza de nullos, estandarización, detección de duplicados y validaciones de calidad.
Analítica	RetailDW (SQL Server)	Modelo estrella: 9 dimensiones (incluye DimFecha con 1.461 filas) + 4 tablas de hechos con surrogate keys.
Visualización	Power BI Service	6 páginas de dashboard publicadas en app.powerbi.com. Modelo semántico con 18+ medidas DAX.
Infraestructura	AWS RDS	Instancia SQL Server Express en us-east-1. Acceso por SQL Server Authentication en puerto 1433.

Figura 1 — Flujo de datos: RetailOLTP → BI_Staging → RetailDW → Power BI Service

3. Base de Datos OLTP — RetailOLTP

La base de datos operacional fue diseñada en Tercera Forma Normal (3FN) para garantizar la integridad referencial y minimizar la redundancia. Incluye todas las restricciones de integridad requeridas (PK, FK, CHECK, NOT NULL) y fue poblada con datos sintéticos pero realistas mediante scripts T-SQL generativos.

3.1 Tablas Principales y Volumen de Datos

Tabla	Registros	Descripción
Clientes	1.000	Personas naturales y jurídicas con segmento (VIP, Premium, Regular, General)
Productos	200	SKUs con precio, costo, categoría y proveedor asignado
Categorías	15	Jerarquía de dos niveles: categoría padre → subcategoría
Proveedores	20	Proveedores con NIT, ciudad y departamento
Tiendas	10	Sedes en diferentes ciudades de Colombia con código T001–T010
Vendedores	20	Asignados a tiendas con canal preferido y fecha de ingreso
CanalVenta	5	Presencial, Online, Telefónico, WhatsApp, Distribuidor
Campañas	12	Campañas comerciales con descuento y período de vigencia
Ventas	50.000	Cabeceras de factura con estado (Completada/Anulada/Pendiente)
DetalleVentas	~175.000	Líneas de venta: cantidad, precio, costo y descuento por producto
InventarioDiario	109.500	Snapshot diario por producto × tienda: entradas, salidas, stock final
MetasComerciales	120	Metas mensuales por tienda y categoría en COP
Devoluciones	~500	Devoluciones con motivo y referencia a la venta original

3.2 Restricciones de Integridad Implementadas

- Claves primarias (IDENTITY) en todas las tablas.
- Claves foráneas con ON DELETE RESTRICT / ON UPDATE CASCADE según corresponde.
- CHECK: PrecioUnitario > 0, CostoUnitario <= PrecioUnitario, DescuentoPct BETWEEN 0 AND 100, Mes BETWEEN 1 AND 12.
- NOT NULL en todos los campos de negocio clave.
- UNIQUE en NumeroFactura, CodigoSKU, NIT de proveedores, Documento de clientes.

4. Zona de Staging — BI_Staging

La base de datos BI_Staging actúa como zona de integración y transformación intermedia entre el OLTP y el Data Warehouse. Es el componente clave de la 'T' en el proceso ELT, donde se aplican todas las reglas de calidad antes de poblar el DW.

4.1 Transformaciones Aplicadas por Tabla

Tabla Staging	Transformaciones Aplicadas
STG_Clientes	Limpieza de nulos (Email, Teléfono, Ciudad). Estandarización a mayúsculas. Validación de segmentos.
STG_Productos	Normalización de nombres de categorías. Detección de margen negativo (CostoUnitario > PrecioUnitario) → RECHAZADO.
STG_Ventas	Validación de fechas futuras o anteriores a 2020. Totales negativos rechazados. Detección de facturas duplicadas.
STG_DetalleVentas	Verificación de integridad referencial. Cantidades y precios inválidos marcados. Líneas huérfanas eliminadas.
STG_Inventario	Stock negativo marcado como SOSPECHOSO. Productos sin referencia OLTP rechazados.
STG_MetasExternas	Metas con ValorMeta <= 0 rechazadas. Mes fuera del rango 1–12 rechazado.

4.2 Resultados de Calidad de Datos

Tras ejecutar el pipeline completo de staging, se obtuvo 0% de errores en todas las tablas, con los volúmenes reales del sistema:

Tabla	Total Reg.	Reg. OK	Reg. Error	% Error
STG_Clientes	1.000	1.000	0	0.00%
STG_Productos	200	200	0	0.00%
STG_Ventas	50.000	50.000	0	0.00%
STG_DetalleVentas	174.878	174.878	0	0.00%
STG_Inventario	109.500	109.500	0	0.00%
STG_MetasExternas	85	85	0	0.00%




Figura 2 — Evidencia de ejecución del pipeline de staging (SSMS)

5. Data Warehouse — RetailDW

El Data Warehouse RetailDW implementa un modelo dimensional en estrella siguiendo la metodología de Ralph Kimball. Todas las tablas de hechos usan surrogate keys enteras (autoincrement), garantizando independencia del OLTP y soporte para SCD. Se incluye una fila 'DESCONOCIDO' (key = -1) en cada dimensión para manejar claves no resueltas sin violar integridad referencial.

5.1 Dimensiones del Modelo

Dimensión	Registros	SCD	Jerarquías
DimFecha	1.461	—	Año → Trimestre → Mes → Semana → Día
DimGeografia	20	Tipo 1	Región → Departamento → Ciudad
DimCliente	1.001	Tipo 2	Región → Ciudad → Segmento → Cliente
DimProducto	201	Tipo 2	Categoría Padre → Categoría → Producto
DimTienda	11	Tipo 1	Región → Ciudad → Tienda
DimVendedor	21	Tipo 1	— (dimensión plana)
DimProveedor	21	Tipo 1	— (dimensión plana)
DimCanalVenta	6	Tipo 1	TipoCanal → Canal
DimPromocion	13	Tipo 1	TipoCampaña → Campaña

5.2 Tablas de Hechos

Tabla de Hechos	Granularidad	Filas Aprox.	Dimensiones
FactVentas	1 línea de venta (prod × cliente × tienda × vendedor × fecha)	~150.000	7
FactInventarioDiario	1 snapshot por día × producto × tienda	~109.500	3
FactMetasComerciales	1 meta por mes × tienda × categoría	~960	4
FactDevoluciones	1 devolución individual	~500	4

5.3 Medidas por Tabla de Hechos

Medida	Tipo	Tabla
ValorVenta	Aditiva	FactVentas
CostoTotal	Aditiva	FactVentas
MargenBruto	Aditiva	FactVentas
Cantidad	Aditiva	FactVentas
Margen %	No aditiva	FactVentas (calculado)

Medida	Tipo	Tabla
Ticket Prom.	No aditiva	FactVentas (calculado)
Entradas	Aditiva	FactInventarioDiario
Salidas	Aditiva	FactInventarioDiario
StockFinal	Semi-aditiva	FactInventarioDiario — NO sumar entre fechas
ValorMeta	Aditiva	FactMetasComerciales
Cumplimiento%	No aditiva	FactMetasComerciales (calculado)

6. Justificación del Modelo Dimensional

6.1 Granularidad de Cada Tabla de Hechos

La granularidad define el nivel de detalle más fino que puede responder cada tabla de hechos. Su definición correcta es la decisión más crítica en el diseño dimensional.

Tabla de Hechos	Granularidad Elegida	Justificación
FactVentas	Una fila por línea de venta (producto × cliente × tienda × vendedor × fecha)	Permite análisis al máximo nivel de detalle. La granularidad por factura perdería información de producto.
FactInventarioDiario	Una fila por día × producto × tienda	El inventario es un estado (stock). La granularidad diaria permite calcular rotación y días de cobertura.
FactMetasComerciales	Una fila por mes × tienda × categoría	Las metas se definen mensualmente. Granularidad más fina sería artificial; más gruesa perdería detalle.
FactDevoluciones	Una fila por devolución individual	Cada devolución tiene un motivo específico. Permite análisis de causas y productos con alta tasa.

6.2 Problemas de Resumibilidad y su Tratamiento

Problema 1 — StockFinal es Semi-aditiva (no sumar entre fechas)

El inventario representa un estado en un punto del tiempo, no un flujo. Sumar StockFinal de enero a diciembre para un producto equivale a contar el mismo inventario 12 veces. El valor correcto es el último día del período o el promedio. Las entradas y salidas sí son aditivas (son flujos).

```
Stock Ultimo Dia = CALCULATE(LASTNONBLANK(FactInventarioDiario[StockFinal],1),
    LASTDATE(DimFecha[Fecha]))
```

Problema 2 — Margen % como ratio no es sumable

El margen porcentual de una categoría no es el promedio de los márgenes unitarios. Siempre debe calcularse como $\text{DIVIDE}([\text{Utilidad Bruta}], [\text{Total Ventas}])$.

Problema 3 — Granularidades diferentes entre Metas y Ventas

FactMetasComerciales trabaja a nivel mensual mientras FactVentas trabaja a nivel de línea de venta. Para comparar cumplimiento se debe agregar ventas al nivel mensual/tienda antes de dividir.

6.3 Dimensiones con SCD Tipo 2

Dimensión	Atributo que cambia	Motivo
DimCliente	Segmento (VIP → Regular)	El historial debe analizarse con el segmento que tenía el cliente en el momento de la compra.
DimProducto	PrecioLista, Categoría	Si un producto cambia de categoría, el análisis histórico de margen se distorsiona sin SCD2.
DimVendedor	TiendaAsignada (traslados)	Las ventas anteriores deben seguir asociadas a la tienda original del vendedor.

Se agregaron columnas FechaInicioSCD, FechaFinSCD y EsVersionActual en DimCliente y DimProducto. El ETL cierra la versión anterior e inserta una nueva cuando detecta cambios en atributos clave.

6.4 Diferencias entre OLTP y OLAP

Aspecto	OLTP — RetailOLTP	OLAP — RetailDW
Objetivo	Registrar transacciones	Analizar datos históricos
Normalización	3FN — sin redundancia	Desnormalizado — redundancia intencional
Tablas	13 tablas relacionadas	13 tablas (9 dim + 4 hechos)
Queries típicas	INSERT/UPDATE de pocas filas	SELECT GROUP BY de millones de filas
Claves	Claves naturales (Documento, SKU)	Surrogate keys enteras (autoincrement)
Fechas	DATETIME en cada transacción	DimFecha con atributos de calendario
Historial	Solo estado actual	SCD2 mantiene historia de cambios
Usuarios	Sistema POS, cajeros	Analistas, gerentes (Power BI)

7. Procesos ETL en T-SQL

Todos los procesos ETL fueron implementados en T-SQL como procedimientos almacenados en la base de datos RetailDW. Existe un orquestador maestro (ETL_Master) que ejecuta el pipeline completo en el orden correcto y registra cada ejecución en la tabla ETL_Log.

7.1 Procedimientos Almacenados Implementados

Procedimiento	Función	Responsable
CargarDimFecha	Genera 1.461 filas (4 años) con atributos de calendario colombiano (feriados incluidos)	Juan Simón
CargarDimensiones	Carga DimCliente, DimProducto, DimTienda, DimVendedor, DimProveedor, DimCanalVenta, DimPromocion, DimGeografia	Juan Simón
CargarFactVentas	Resuelve surrogate keys, calcula ValorVenta, CostoTotal, MargenBruto e inserta ~150K filas	Juan Simón
CargarFactInventario	Carga snapshot diario de inventario por producto × tienda	Juan Simón
CargarFactMetas	Integra metas del OLTP + CSV externo. Resuelve claves de tienda y categoría	Juan Simón
CargarFactDevoluciones	Procesa devoluciones con referencia a la venta original y motivo	Juan Simón
ValidarCalidadDatos	Post-carga: verifica integridad referencial, NULLs en FKs y registros huérfanos	Juan Simón
ETL_Master	Orquestador: ejecuta todos los procedimientos en orden, maneja errores y registra en ETL_Log	Juan Simón

7.2 Tabla ETL_Log — Bitácora de Ejecuciones

Proceso	Estado	Leídos	Cargados	Rechazados	Duración
CargarDimFecha	COMPLETADO	1.461	1.461	0	2s
CargarDimGeografia	COMPLETADO	1.000	19	0	<1s
CargarDimCliente	COMPLETADO	1.000	1.000	0	<1s
CargarDimProducto	COMPLETADO	200	200	0	<1s
CargarDimTienda	COMPLETADO	10	10	0	<1s
CargarDimVendedor	COMPLETADO	20	20	0	<1s
CargarDimProveedor	COMPLETADO	20	20	0	<1s
CargarDimCanalVenta	COMPLETADO	5	5	0	<1s
CargarDimPromocion	COMPLETADO	12	12	0	<1s

	NombreProceso	Estado	RegistrosLeídos	RegistrosCargados
1	CargarDimFecha	COMPLETADO	1461	1461
2	CargarDimGeografia	COMPLETADO	1000	19
3	CargarDimCliente	COMPLETADO	1000	1000
4	CargarDimProducto	COMPLETADO	200	200
5	CargarDimTienda	COMPLETADO	10	10
6	CargarDimVendedor	COMPLETADO	20	20
7	CargarDimProveedor	COMPLETADO	20	20
8	CargarDimProveedor	COMPLETADO	20	20
9	CargarDimCanalVenta	COMPLETADO	5	5
10	CargarDimPromocion	COMPLETADO	12	12

Figura 3 — Evidencia de ejecución del ETL en SSMS

7.3 Resolución de Surrogate Keys

En cada procedimiento ETL de carga de hechos se resuelven las surrogate keys mediante JOIN con las dimensiones correspondientes. Cualquier clave natural no encontrada en una dimensión se mapea a la fila DESCONOCIDO (key = -1), evitando NULLs en las claves foráneas y garantizando la integridad referencial del DW.

8. Validaciones y Calidad de Datos

El pipeline implementa validaciones en dos etapas: en la zona de staging (antes de cargar al DW) y en una fase de post-carga (ValidarCalidadDatos).

8.1 Validaciones en Staging

- Limpieza de nulos: campos opcionales (Email, Teléfono, Ciudad) completados con valores por defecto.
- Estandarización: nombres de ciudades y categorías normalizados a mayúsculas y sin tildes.
- Validación de rangos: fechas futuras, totales negativos, meses inválidos marcados como RECHAZADO.
- Detección de duplicados: por NumeroFactura — solo se carga el primer registro.
- Integridad referencial staging: líneas de venta huérfanas (sin VentaID en STG_Ventas) marcadas como RECHAZADO.
- Margen negativo: productos con CostoUnitario mayor a PrecioUnitario marcados para revisión.

8.2 Validaciones Post-Carga (ValidarCalidadDatos)

- Verificación de que ninguna FK en tablas de hechos apunte a claves no existentes en dimensiones.
- Conteo de NULLs en columnas de medidas (ValorVenta, CostoTotal, StockFinal, ValorMeta).
- Comparación de totales entre staging y DW para detectar pérdida de registros.
- Verificación de que todos los registros con clave no resuelta apunten a la fila -1 (DESCONOCIDO).

8.3 Evidencias de Ejecución

Las evidencias visuales de la ejecución del pipeline fueron capturadas en SSMS y se incluyen como imágenes de referencia en el repositorio del proyecto (imagenes/sebastian/evidencia_staging_qa.png y imagenes/sebastian/evidencia_dw_etl.png).

9. Visualización en Power BI

El modelo semántico de Power BI se conectó al Data Warehouse RetailDW en modo Import. Se configuraron todas las relaciones Many-to-One entre tablas de hechos y dimensiones, y se marcó DimFecha como Date Table para habilitar funciones de Time Intelligence en DAX.

9.1 Estructura del Dashboard (6 Páginas)

Página	Nombre	Visualizaciones Principales
1	Dashboard Ejecutivo	4 KPI Cards (Ventas, Utilidad, Margen%, Cumplimiento%), línea mensual YoY, Top 5 tiendas/productos, Gauge de cumplimiento.
2	Análisis de Ventas	Gráfico de área mensual, barras apiladas por categoría/tienda, tabla de vendedores, donut por canal, mapa de Colombia.
3	Inventario	Cards de Inventario Promedio y Rotación, Top 10 productos con menor stock, evolución semanal, mapa de cobertura por tienda.
4	Rentabilidad	Barras agrupadas Ingresos vs Costos por categoría, scatter Margen% vs Ventas, tabla tienda con margen, treemap.
5	Cumplimiento de Metas	Multi-row card por tienda, barras Ventas vs Meta por mes, matriz tienda × mes con formato condicional (semáforo).
6	Exploración OLAP	Matrix con drill-down Año→Trim→Mes→Día, drill-through a Página 2, segmentador jerárquico Categoría→Producto.

9.2 Acceso al Dashboard Publicado

El tablero fue publicado en Power BI Service en el workspace **Proyecto3-RetailBI**.

<https://app.powerbi.com/view?r=eyJrIjoimjA3NDhjNDktZTBjNi00OTcxLTgwMDgtNTBmYzczOGZlMTBliiwidCI6IjksZjdiNTVlLTljYmUtNDY3Yi04MTQzLTkxOTc4MjkxOGFmYiIsImMiOjR9>

9.3 Conexión al Servidor SQL

Parámetro	Valor
Endpoint	retailbi-sqlserver-xlarge2.cq05vkzr8bgv.us-east-1.rds.amazonaws.com
Puerto	1433
Base de datos	RetailDW
Usuario SQL	retail_admin
Modo conexión	Import (no DirectQuery)

10. Medidas DAX

Se implementaron 18 medidas DAX organizadas en grupos temáticos dentro de la tabla de medidas _Medidas. Las medidas cubren desde sumas básicas hasta inteligencia temporal avanzada y rankings dinámicos.

#	Medida	Grupo	Tipo DAX
1	Total Ventas	Base Ventas	SUM — Aditiva
2	Total Costo	Base Ventas	SUM — Aditiva
3	Utilidad Bruta	Base Ventas	Calculada — Aditiva
4	Margen Bruto %	Base Ventas	DIVIDE — No aditiva
5	Cantidad Vendida	Base Ventas	SUM — Aditiva
6	Ticket Promedio	Base Ventas	DIVIDE / DISTINCTCOUNT
7	Ventas Año Anterior	Time Intelligence	CALCULATE + SAMEPERIODLASTYEAR
8	Crecimiento Ventas %	Time Intelligence	DIVIDE — variación YoY
9	Ventas YTD	Time Intelligence	TOTALYTD
10	Promedio Movil 3M	Time Intelligence	DATESINPERIOD — ventana 90 días
11	Total Meta	Metas	SUM(FactMetasComerciales)
12	Cumplimiento Meta %	Metas	DIVIDE([Total Ventas],[Total Meta])
13	Brecha Meta	Metas	Diferencia Ventas – Meta
14	Inventario Promedio	Inventario	AVERAGEX — semi-aditiva
15	Rotacion Inventario	Inventario	DIVIDE(Costo, Inv. Promedio)
16	Ranking Producto	Rankings	RANKX(ALL(DimProducto), ...)
17	Ranking Tienda Ventas	Rankings	RANKX(ALL(DimTienda), ...)
18	Participacion Ventas %	Participación	DIVIDE([Total Ventas], CALCULATE(..., ALL))

Consideraciones Técnicas DAX

- **Context transition:** todas las medidas de FactInventarioDiario usan CALCULATE para forzar transición de contexto en tablas calculadas.
- **USERELATIONSHIP:** no fue necesario en este modelo al no existir relaciones inactivas.
- **ALL vs ALLEXCEPT:** la medida Participacion Ventas % usa ALL(DimProducto) para remover el filtro de producto manteniendo los de tienda y fecha.
- **Medidas semi-aditivas:** Inventario Promedio usa AVERAGEX en lugar de AVERAGE para iterar correctamente sobre fechas.
- **DimFecha marcada como Date Table:** requisito obligatorio para SAMEPERIODLASTYEAR y TOTALYTD.

11. Fuentes de Datos Externas

Se integraron dos fuentes externas al pipeline ETL, cargadas mediante el script Python `load_csvs.py` en la zona de staging antes de ejecutar el ETL.

Archivo	Formato	Filas	Descripción
metas_mensuales.csv	CSV	85	Metas comerciales por tienda y categoría. Columnas: Año, Mes, CódigoTienda, NombreCategoría, ValorMeta.
inventario_fisico.csv	CSV	~300	Ajustes manuales de inventario físico. Columnas: FechaConteo, CódigoSKU, CódigoTienda, StockFísico, Observación.

Proceso de Integración

- Los CSV se cargan a BI_Staging mediante el script Python (pyodbc + pandas) definido en `08_scripts/load_csvs.py`.
- Las credenciales de conexión se almacenan en `.env` (excluido del repositorio público).
- Una vez en staging, los datos pasan por el mismo pipeline de validación que los datos OLTP.
- Las metas externas se fusionan con las metas del OLTP durante `CargarFactMetas`.

12. Ética y Uso de IA en el Proyecto

En cumplimiento del numeral 12 del enunciado del Proyecto 3 de Bases de Datos Avanzadas (SI3009, Universidad EAFIT, 2026-1), el equipo declara de manera explícita y transparente el uso que hizo de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del proyecto, así como las responsabilidades que permanecieron íntegramente en manos del equipo.

12.1 Estimación del Porcentaje de Participación de la IA

La siguiente tabla resume el porcentaje estimado de apoyo de IA por componente del proyecto. Los porcentajes representan la proporción del trabajo inicial que fue sugerido o generado por IA antes de la revisión, adaptación y validación por parte del equipo.

Componente del Proyecto	% Apoyo IA	Descripción del apoyo
Generación de scripts SQL (CREATE TABLE)	70%	Estructura inicial de tablas, PK/FK y restricciones básicas. El equipo ajustó tipos, restricciones de negocio y relaciones.
Datos sintéticos (INSERT/generación aleatoria)	80%	Scripts de generación de datos con RAND(), NEWID() y lógica de distribución. El equipo validó coherencia de negocio.
Diseño inicial del modelo estrella	50%	Propuesta inicial de dimensiones y hechos. La granularidad, jerarquías y decisión de SCD2 fueron íntegramente del equipo.
Procedimientos ETL base (CargarDim*, CargarFact*)	60%	Estructura básica de los SP. La resolución de claves huérfanas, manejo de errores y lógica de negocio son del equipo.
Medidas DAX básicas (SUM, DIVIDE simples)	65%	Medidas del grupo 1. Las medidas de Time Intelligence y rankings fueron construidas manualmente por el equipo.
Medidas DAX avanzadas (RANKX, SAMEPERIODLASTYEAR)	30%	El equipo construyó estas medidas con apoyo puntual de IA para la sintaxis. La lógica de negocio es del equipo.
Validaciones de calidad de datos (staging QA)	45%	Estructura de checks básicos generada con IA; la lógica de negocio colombiana fue definida por el equipo.
Diseño del dashboard Power BI	20%	Solo sugerencias de tipos de visual. El diseño, paleta de colores, layout y storytelling fueron del equipo.
Documentación técnica (diccionario, modelos)	40%	Plantillas iniciales con IA. El contenido específico, justificaciones conceptuales y evidencias son del equipo.
Infraestructura Azure/AWS	5%	Casi en su totalidad ejecutada por el equipo. IA aportó solo comandos de referencia de configuración.
Sustentación del proyecto	0%	Realizada íntegramente por los estudiantes. Sin apoyo de IA.

Estimación global del proyecto: aproximadamente el 45–50% del código y contenido inicial fue generado o sugerido por IA (principalmente Claude Sonnet y GitHub Copilot). Sin embargo, el 100% fue revisado, adaptado, validado y ejecutado por el equipo. Las decisiones de diseño arquitectónico, granularidad, lógica de negocio, resolución de errores operativos y la ejecución en el ambiente real son responsabilidad íntegra de los estudiantes.

12.2 Partes del Proyecto Realizadas con Apoyo de IA

A. Scripts SQL — Apoyo Alto (60–80%)

Se utilizó IA para generar la estructura inicial de las tablas OLTP (CREATE TABLE con PK y FK), los scripts de generación de datos sintéticos (50.000 ventas, 175.000 líneas, procedimientos con RAND() y distribuciones), y las

plantillas base de los procedimientos ETL. Intervención del equipo: ajuste de tipos de datos para Colombia (VARCHAR para cédulas con dígito de verificación), restricciones CHECK de negocio (costo <= precio, descuento BETWEEN 0 AND 100), relaciones específicas entre Ventas-Tiendas-Vendedores, y toda la lógica de manejo de errores en los ETL.

B. Diseño Inicial del Modelo Estrella — Apoyo Medio (50%)

La IA proporcionó una primera propuesta de qué tablas podrían ser dimensiones y cuáles hechos. Sin embargo, todas las decisiones críticas fueron del equipo: la granularidad de cada tabla de hechos (por línea vs. por factura), la decisión de implementar SCD Tipo 2 en DimCliente y DimProducto, el manejo de la semi-aditividad de StockFinal, y la creación de la fila DESCONOCIDO (-1) para integridad referencial.

C. Medidas DAX Básicas — Apoyo Medio (65%)

Las 8 medidas del Grupo 1 (sumas y ratios simples) fueron generadas con apoyo de IA como punto de partida. Las medidas de Time Intelligence (SAMEPERIODELASTYEAR, TOTALYTD, Promedio Móvil 3M), los rankings dinámicos (RANKX), y las medidas de inventario semi-aditivas (AVERAGEX) fueron construidas y debuggeadas manualmente por el equipo.

12.3 Partes Realizadas Íntegramente por el Equipo (Sin IA)

- Creación y configuración del servidor en AWS RDS: instancia SQL Server Express, grupos de seguridad, reglas de entrada para puerto 1433, configuración de usuarios y contraseñas.
- Ejecución e integración completa de todos los scripts en el servidor real: depuración de errores de sintaxis SQL Server, manejo de timeouts en scripts de generación masiva (50K+ filas), y ajustes por limitaciones de la versión Express.
- Desarrollo real de los tableros en Power BI Desktop: configuración de relaciones, formato de visualizaciones, jerarquías, drill-through, formato condicional (semáforo de metas) y publicación en Power BI Service.
- Resolución de problemas operativos imprevistos: claves foráneas que fallaban por orden de inserción, productos con margen negativo en datos sintéticos, fechas duplicadas en staging, y errores de codificación en los CSV (UTF-8 vs. Latin-1).
- Revisión y coherencia del informe técnico: todas las justificaciones conceptuales (granularidad, semi-aditividad, SCD2, diferencias OLTP vs. OLAP) fueron redactadas y defendidas por el equipo.
- Sustentación oral del proyecto: la capacidad de defender las decisiones de diseño, explicar problemas de agregación, demostrar el modelo en vivo y responder preguntas del profesor es íntegramente responsabilidad del equipo.

12.4 Herramientas de IA Utilizadas

Herramienta	Uso Principal	Proporción del uso
Claude (Anthropic)	Generación de scripts SQL, estructura ETL, DAX básico, documentación inicial	~70% del apoyo total
GitHub Copilot	Autocompletado de código T-SQL en SSMS y Python (load_csvs.py)	~20% del apoyo total
ChatGPT (OpenAI)	Consultas puntuales de sintaxis SQL Server y funciones DAX	~10% del apoyo total

12.5 Código de Ética del Equipo

- **Transparencia total:** el equipo declara sin omisiones el uso de IA, conforme al espíritu del numeral 12 del enunciado.
- **Responsabilidad intelectual:** todo código generado por IA fue comprendido, revisado y adaptado antes de ser utilizado. El equipo puede explicar línea a línea cualquier script del repositorio.

- **Aprendizaje genuino:** el uso de IA se orientó a acelerar tareas repetitivas (generación de datos sintéticos, plantillas) para dedicar más tiempo a las decisiones conceptuales de alto valor (granularidad, SCD, resumibilidad).
- **No suplantación:** ninguna sección conceptual del informe ni la sustentación fue delegada a la IA. Las justificaciones de diseño reflejan el entendimiento real del equipo.
- **Coherencia end-to-end:** el equipo entiende cómo cada componente se conecta con los demás y puede defender la arquitectura completa ante el profesor.

El equipo reconoce que la IA es una herramienta poderosa que, utilizada responsablemente, permite construir soluciones más robustas en menos tiempo. Sin embargo, ninguna IA puede sustituir la comprensión profunda de los conceptos de modelado dimensional, las decisiones de granularidad, el manejo de datos reales con sus inconsistencias, ni la capacidad de defender el diseño ante el profesor. Ese conocimiento es, y debe ser, propiedad del equipo.

13. Conclusiones

Pipeline BI end-to-end funcional.	El equipo logró implementar y desplegar una solución completa desde el OLTP hasta Power BI Service, incluyendo staging, Data Warehouse dimensional, ETL en T-SQL y 6 páginas de dashboard analítico. Todos los componentes están operativos en AWS RDS.
Calidad de datos garantizada.	El pipeline de validación en staging procesó más de 336.000 registros con 0% de error tras las transformaciones, demostrando la robustez del proceso de integración.
Modelo dimensional correcto.	La granularidad de cada tabla de hechos fue definida conscientemente, se identificaron correctamente las medidas semi-aditivas (StockFinal) y no aditivas (Margen%, ratios), y se implementó SCD Tipo 2 en DimCliente y DimProducto.
ETL robusto con bitácora.	Los 9 procedimientos ETL ejecutaron sin errores, registrando cada ejecución en la tabla ETL_Log con tiempos, registros procesados y estados. El orquestador ETL_Master garantiza la ejecución en el orden correcto.
Análisis DAX avanzado.	Las 18 medidas DAX implementadas incluyen Time Intelligence real (SAMEPERIODLASTYEAR, TOTALYTD, ventana móvil), rankings dinámicos (RANKX) y manejo correcto de medidas semi-aditivas con AVERAGEX.
Uso responsable de IA.	El equipo utilizó herramientas de IA para acelerar tareas repetitivas, pero mantuvo la responsabilidad intelectual sobre todas las decisiones de diseño, la ejecución real del ambiente y la capacidad de sustentación. El balance entre eficiencia y aprendizaje genuino fue el criterio guía.

14. Referencias

[1] Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.

[2] Microsoft Corporation. (2024). T-SQL Reference — SQL Server 2022. Microsoft Docs. <https://docs.microsoft.com/en-us/sql/t-sql/>

[3] Microsoft Corporation. (2024). DAX Reference — Power BI. Microsoft Docs. <https://docs.microsoft.com/en-us/dax/>

[4] Amazon Web Services. (2024). Amazon RDS for SQL Server User Guide. AWS Documentation. <https://docs.aws.amazon.com/AmazonRDS/>

[5] Microsoft Corporation. (2024). Power BI Documentation. Microsoft Docs. <https://docs.microsoft.com/en-us/power-bi/>

[6] DANE — Departamento Administrativo Nacional de Estadística. (2024). Codificación DIVIPOLA. Colombia. <https://www.dane.gov.co/>

[7] Universidad EAFIT. (2026). Enunciado Proyecto 3 — SI3009 Bases de Datos Avanzadas. Medellín, Colombia.